Projet Covid

Margaux Bailleul / Oriane Duclos / Marie Guibert

2023-05-08

```
library(tidyverse)
library(forecast)
library(tidyquant)
library(caschrono)
library(stats)
library(tseries)
library(lmtest)
```

Importations des données

Tout d'abord, on importe les données et on sélectionne les données concernant la France.

```
donnees_fr <- read.csv("covid_france.csv",sep=",")
summary(donnees_fr)
```

```
##      date             new_cases
##  Length:1203        Min.   :     0
##  Class :character   1st Qu.:  2968
##  Mode  :character   Median : 12174
##                     Mean   : 32315
##                     3rd Qu.: 32913
##                     Max.   :500563
##                     NA's   :1
```

Les données ci-dessus comprennent une variable temporelle et une variable caractérisée par un enregistrement journalier des nouveaux cas de Covid-19 en France.

```
min(donnees_fr$date)
```

```
## [1] "2020-01-03"
```

```
max(donnees_fr$date)
```

```
## [1] "2023-04-19"
```

Grâce à cette étape, nous pouvons observer que notre série temporelle débute le 1er Mars 2020 et se termine le 19 Avril 2023. Notre étude a donc une plage d'environ de 3 ans.

Transformation des données en série temporelle

Premièrement, nous allons transformer nos données en séries temporelles pour pouvoir réaliser notre analyse.

```
ts_donnees_fr <- ts(donnees_fr$new_cases,start = c(2020,1,3), frequency = 365)
# class(ts_donnees_fr)
```

Première partie

```
plot(ts_donnees_fr)
```

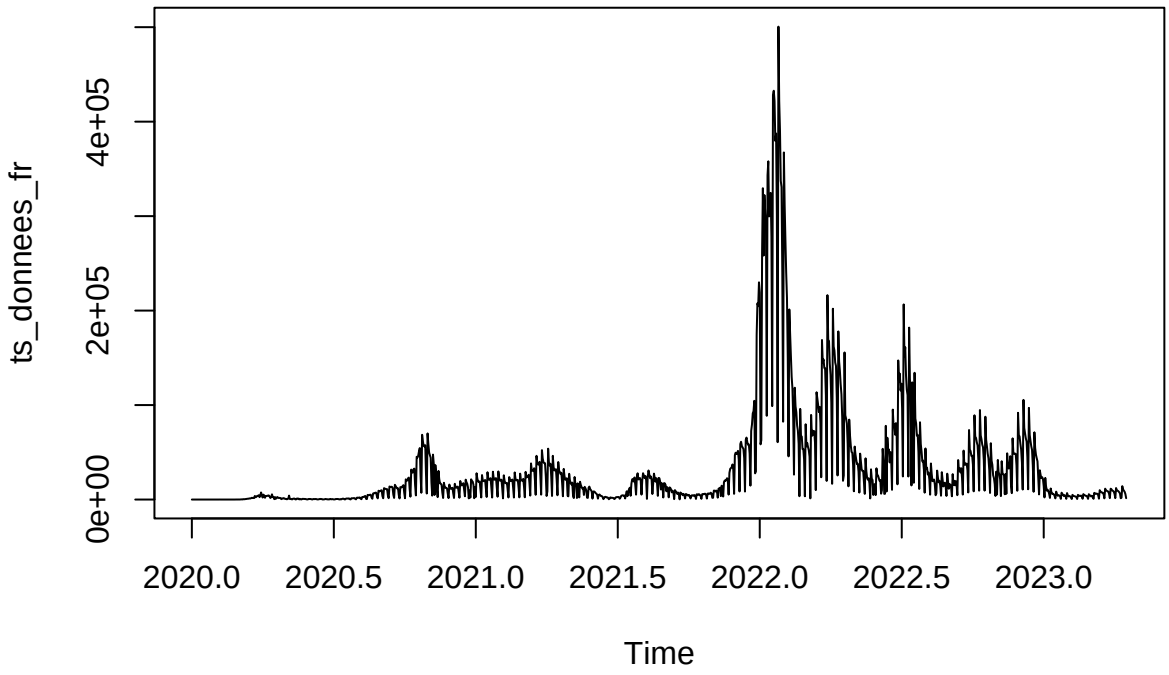

Ce premier graphique nous montre une hausse brutale des nouveaux cas de covids en 2022. Afin de pouvoir continuer notre analyse de façon cohérente, nous allons diviser notre série en 3 parties : avant, pendant et après ce choc en 2022.

Application de la décomposition saisonnière à la série temporelle pour visualiser les tendances et les motifs saisonniers. Nous supprimons les données manquantes afin de ne garder que celles qui sont pertinentes.

```
decomp_ts <- stl(na.omit(ts_donnees_fr), s.window = "periodic")
autoplot(decomp_ts)
```

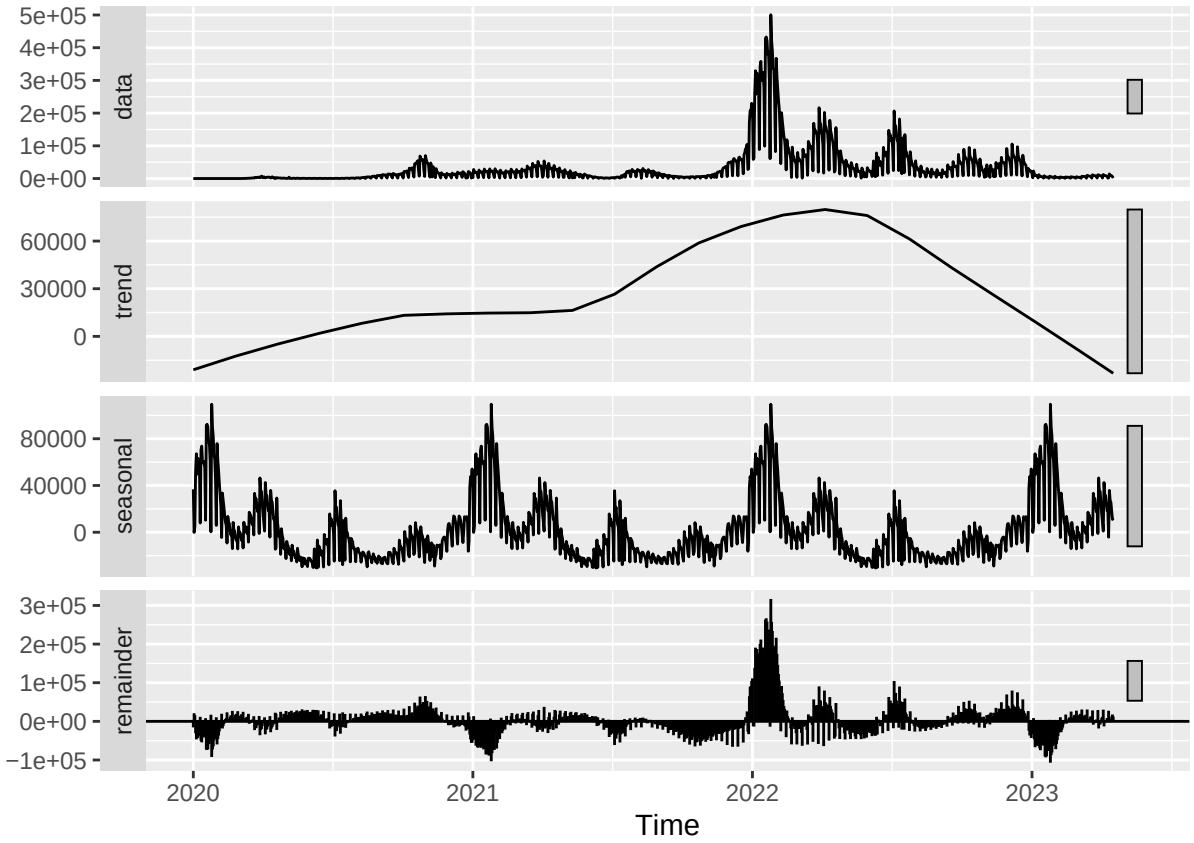

Cette étape nous permet d'observer une tendance à la hausse entre 2020 et 2022, puis à partir de 2022, une tendance à la baisse.
De plus, nous pouvons voir une saisonnalité annuelle.

Decomposition par moyenne mobile

La fonction decompose permet d'extraire d'une série temporelle (via la méthode de la moyenne mobile)

```
serie_decomp<-decompose(na.omit(ts_donnees_fr),type=c('additive'))
decomp_ts <- stl(na.omit(ts_donnees_fr), s.window = "periodic")
autoplot(serie_decomp)
```

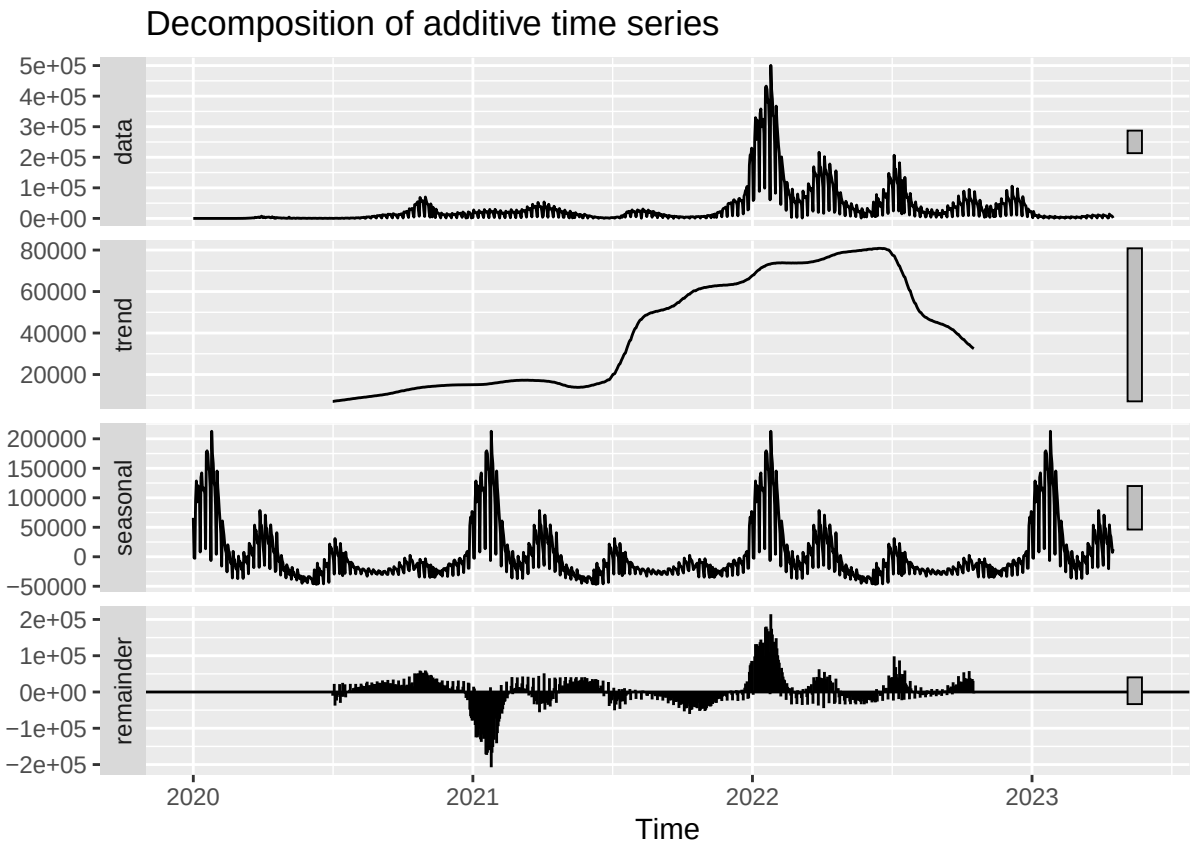

Division de notre série

Nous décidons de créer trois sous-séries de notre série initiale afin de pouvoir réaliser le traitement des données. Notre objectif est d'isoler le cas particulier de l'année 2022 pour avoir une étude correcte.

```
serie1 <- donnees_fr |>
  filter(date<="2021-12-22")
# serie1
ts_serie1 <- ts(serie1$new_cases,start = c(2020,1,3), frequency = 365)



serie2 <- donnees_fr |>
  filter(date>"2021-12-22", date<="2023-01-05")
# serie2

ts_serie2 <- ts(serie2$new_cases,start = c(2021,31,12), frequency = 365)



serie3 <- donnees_fr |>
  filter(date>"2023-01-05")

ts_serie3 <- ts(serie3$new_cases,start = c(2023,2,5), frequency = 365)
```

Nous avons choisi de scinder notre série en trois périodes : - avant le 22 Décembre 2021 - entre le 23 Décembre 2021 et le 5 Janvier 2023 - après le 6 Janvier 2023

Nous pouvons maintenant les visualiser :

```
plot(ts_serie1,main="Nouveaux cas de covid-19 en France entre 2020 et 2022")
```

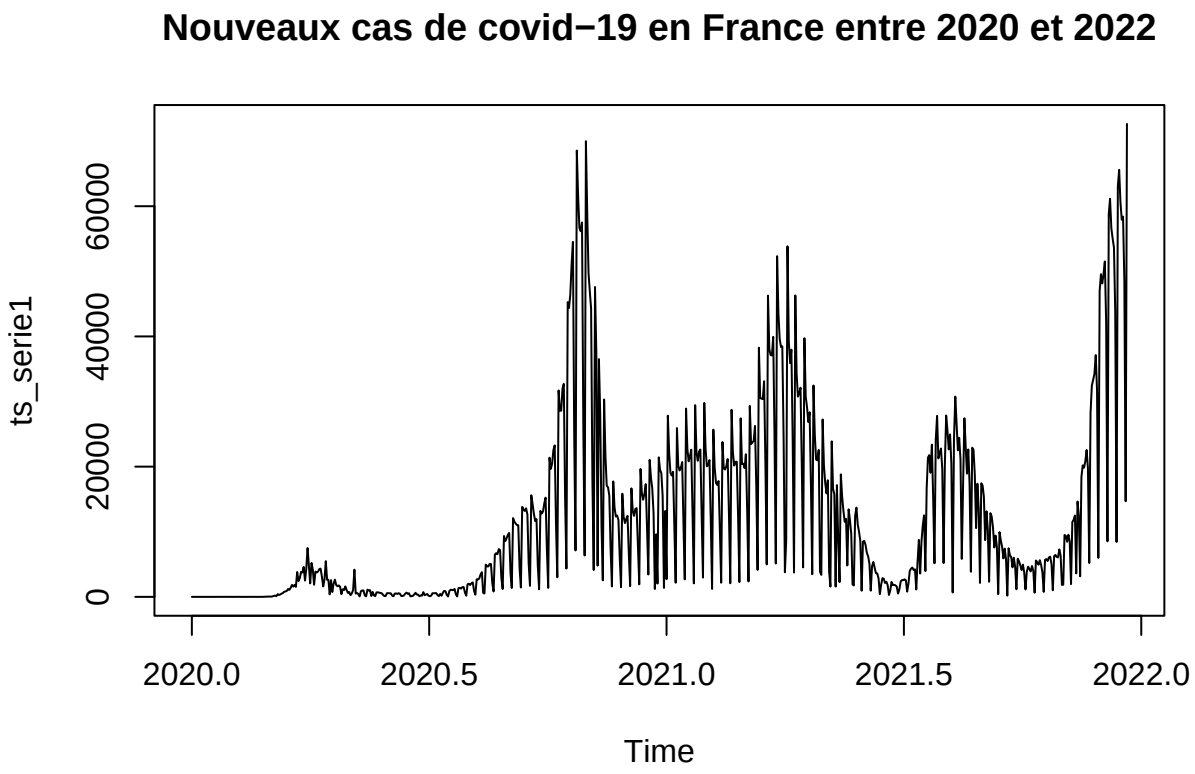


```
plot(ts_serie2,main="Nouveaux cas de covid-19 en France entre 2022 et 2023")
```

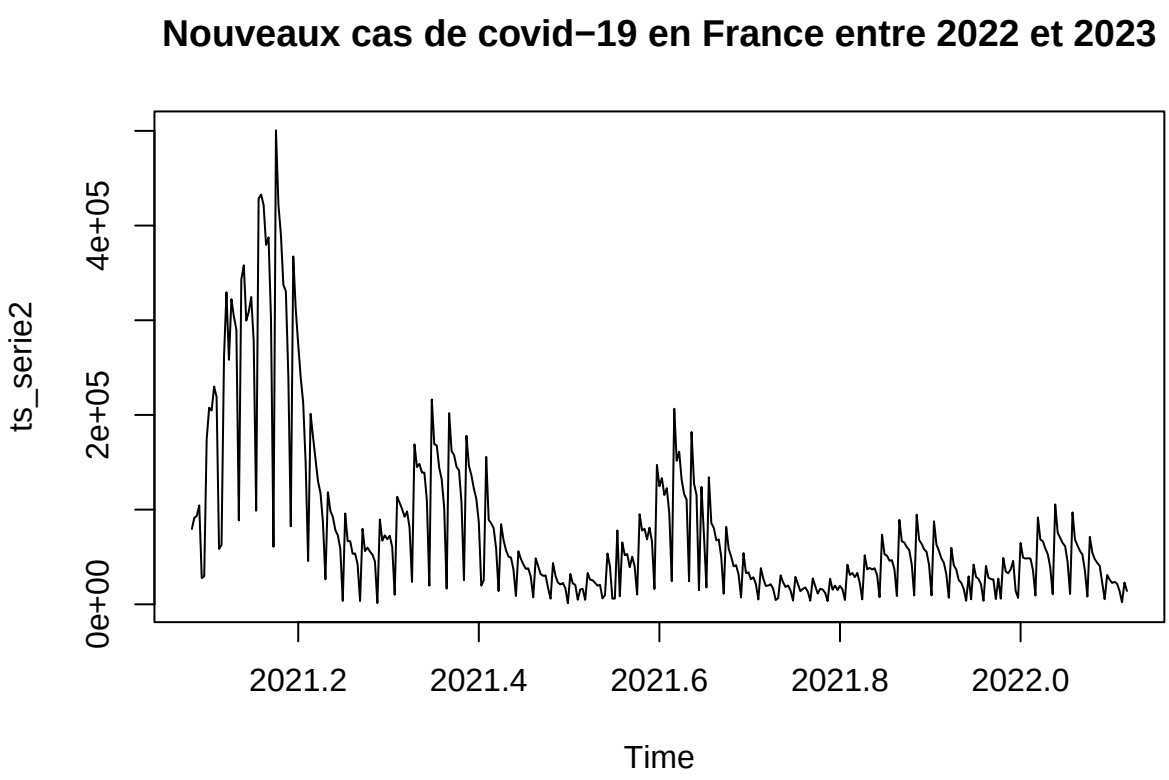


```
plot(ts_serie3,main="Nouveaux cas de covid-19 en France en 2023")
```

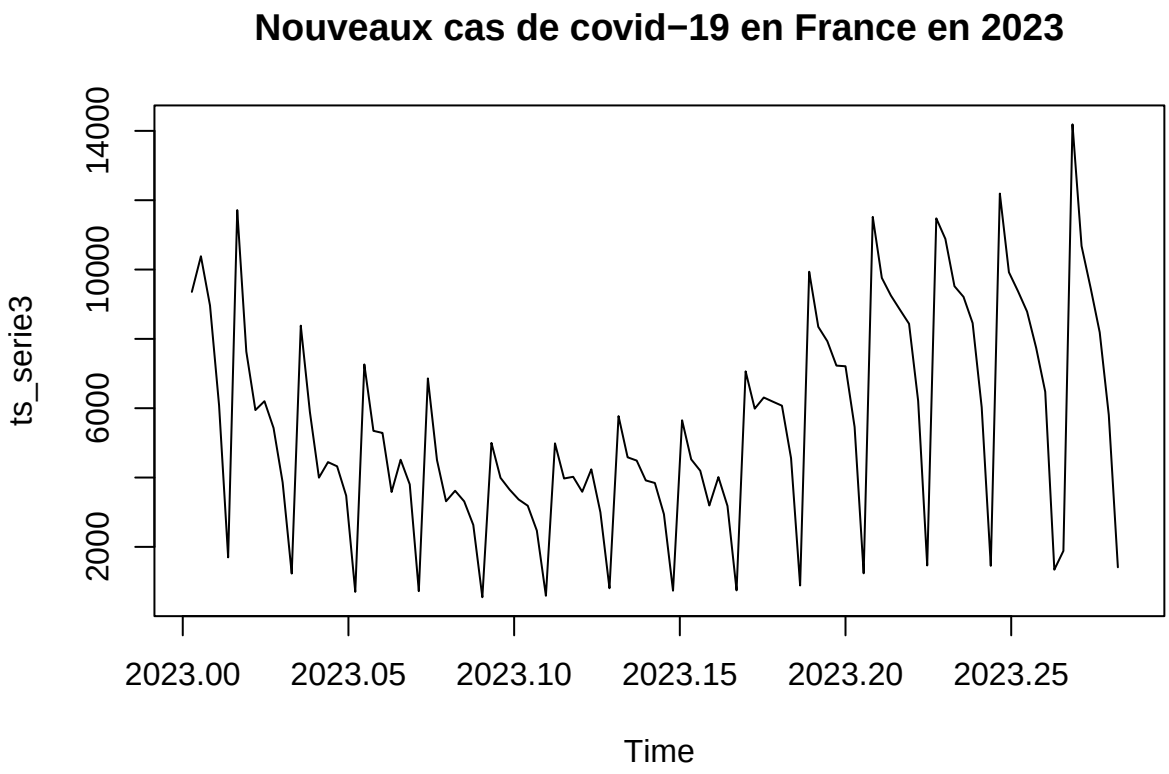

Grâce à cette division, nous allons pouvoir étudier chaque sous-série pertinemment.

Analyse de la première sous-série

Nous avons décidé de nous focaliser sur la première sous-série.
Ce choix est expliqué grâce à notre connaissance des évènements durant cette année particulière. En effet, les confinements ont pu avoir des conséquences sur notre série et nos données. Notre étude commence donc le 1er Mars 2020 et s'étend jusqu'au 22 décembre 2021.

Pour rappel, notre série présente une tendance à la hausse comme le montre le graphique ci-dessous. Elle présente aussi une saisonnalité, mais elle n'est pas régulière. En effet, les différentes hausses de nouveaux cas de covid dépendent des confinements et des mesures sanitaires mises en place.

```
autoplot(ts_serie1)+
  geom_smooth(method = lm,color="blue")+
  ggtitle("Nouveaux cas de covids en France entre 2020 et 2022")
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

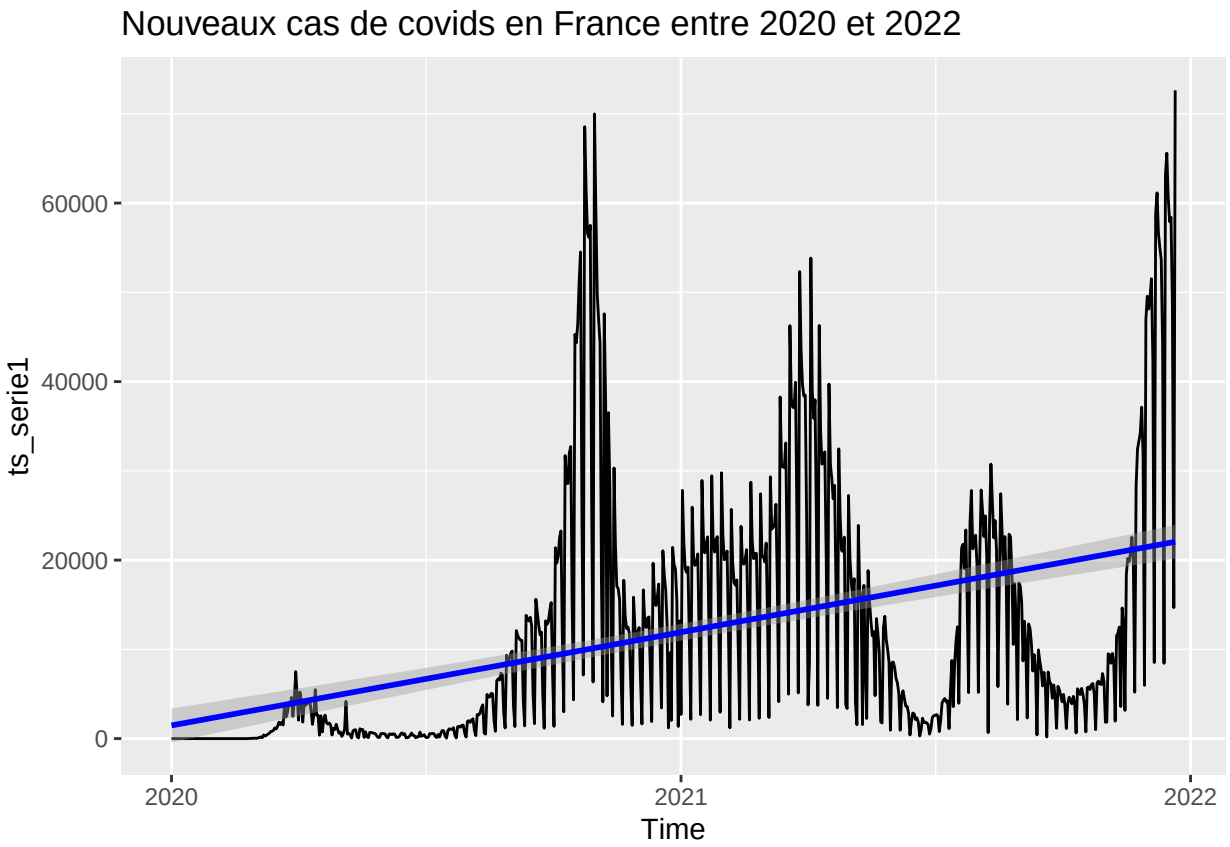

On va d'abord chercher à décrire notre série grâce à des indicateurs descriptifs simples.

```
mean(ts_serie1)
```

```
## [1] 11763.34
```

Entre le 1er Mars 2020 et le 22 Décembre 2022, la moyenne des nouveaux cas de covids par jour était de 11 763 cas en France.

```
ts_serie1 |>
  ggtsdisplay(plot.type = "scatter",smooth=FALSE)
```

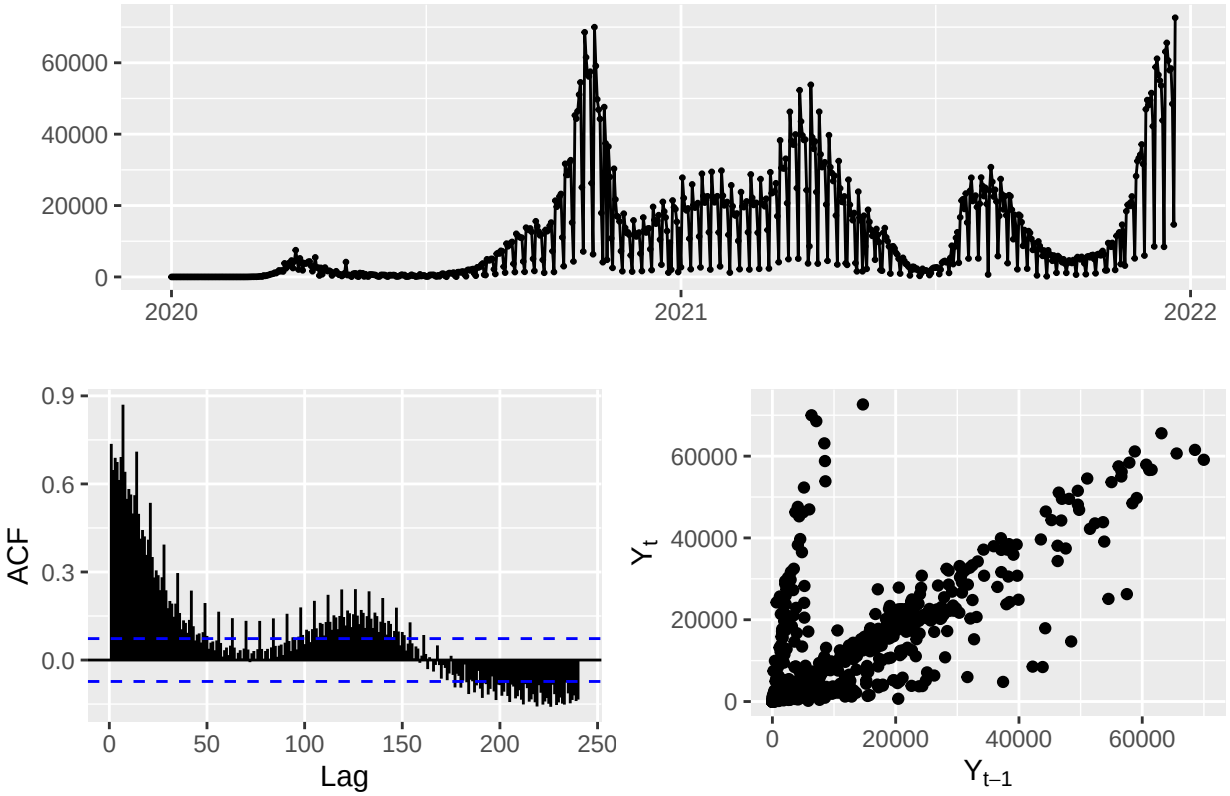

Nous pouvons faire quelques observations sur le graphique de l'ACF. Ce graphique nous permet de détecter une structure de corrélation du réseau. Dans notre cas, plusieurs autocorrélations présentent des valeurs significativement non nulles, ce qui signifie que la série chronologique n'est pas aléatoire.

Afin d'avoir une analyse plus exhaustive, nous pouvons analyser l'ACF et la PACF

```
acf <- acf(ts_serie1)
```

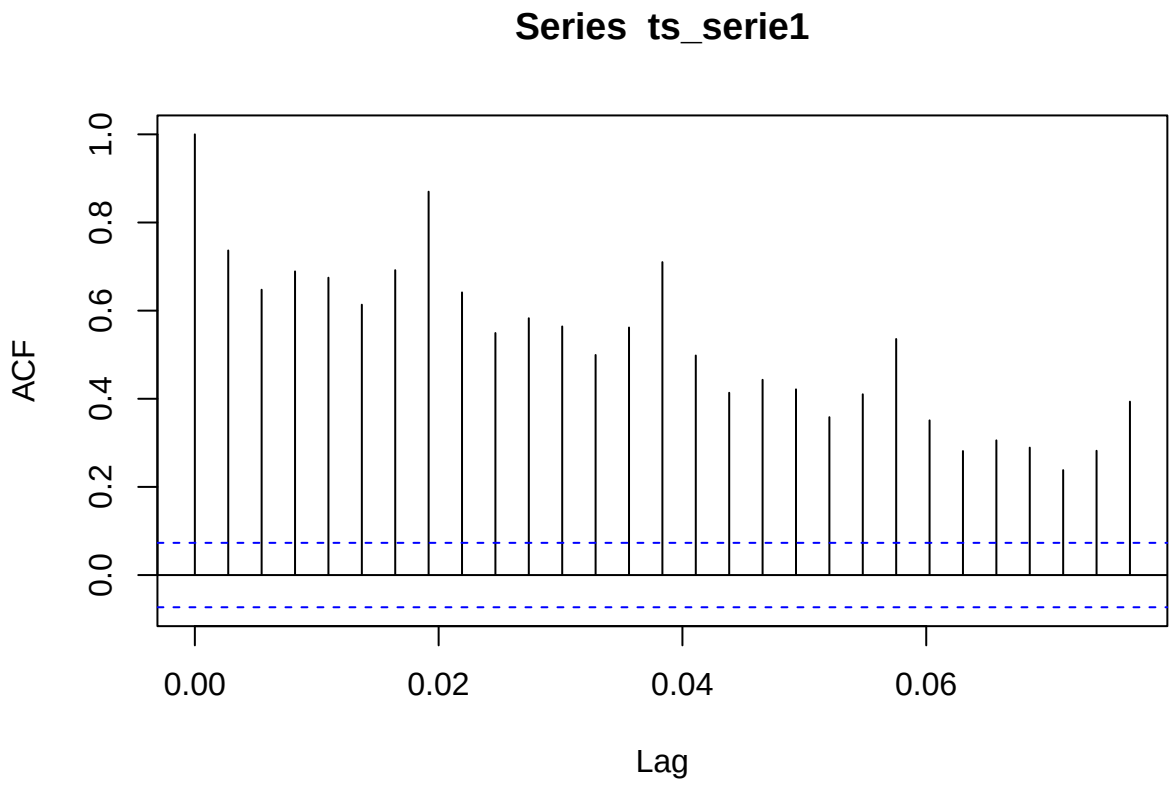


```
print(data.frame(acf$lag,acf$acf))
```

```
##        acf.lag   acf.acf
## 1  0.000000000 1.0000000
## 2  0.002739726 0.7365088
## 3  0.005479452 0.6474386
## 4  0.008219178 0.6890097
## 5  0.010958904 0.6747133
## 6  0.013698630 0.6134778
## 7  0.016438356 0.6918098
## 8  0.019178082 0.8699193
## 9  0.021917808 0.6413418
## 10 0.024657534 0.5491586
## 11 0.027397260 0.5827231
## 12 0.030136986 0.5640830
## 13 0.032876712 0.4993613
## 14 0.035616438 0.5617146
## 15 0.038356164 0.7100309
## 16 0.041095890 0.4981678
## 17 0.043835616 0.4136221
## 18 0.046575342 0.4429968
## 19 0.049315068 0.4213644
## 20 0.052054795 0.3582470
## 21 0.054794521 0.4101775
## 22 0.057534247 0.5356155
```

```
## 23 0.060273973 0.3509638
## 24 0.063013699 0.2813732
## 25 0.065753425 0.3056083
## 26 0.068493151 0.2891480
## 27 0.071232877 0.2380992
## 28 0.073972603 0.2820158
## 29 0.076712329 0.3934595
```

```
# plot(data.frame(acf$lag,acf$acf))
```

Ce graphique nous permet d'observer une corrélation hebdomadaire. En effet, nous pouvons remarquer un pic plus élevé tous les 7 jours.

Puisque notre série montre une corrélation hebdomadaire, nous avons choisi d'étudier une série temporelle avec une fréquence de 7 jours.

```
ts_serie_semaine <- ts(ts_serie1, frequency = 7)
autoplot(ts_serie_semaine) # Visualisation des données
```

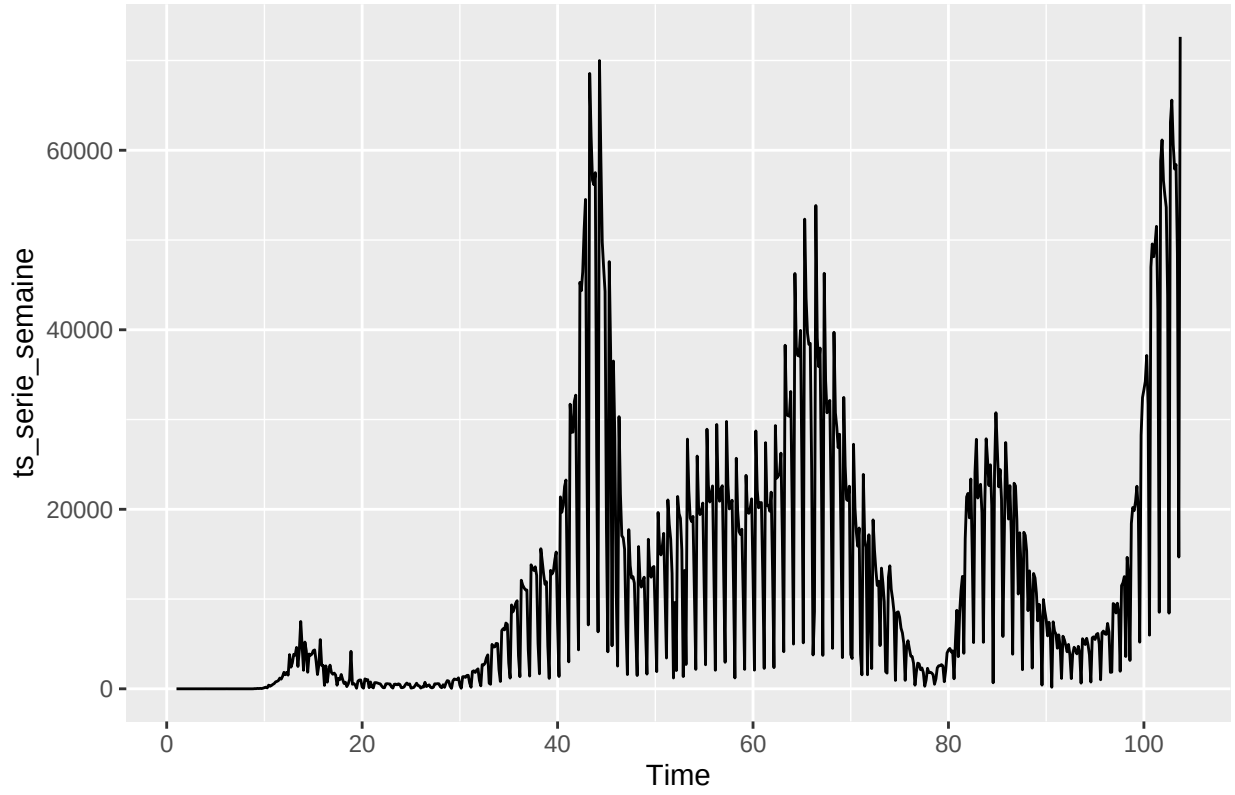


```
decomp_ts <- stl(na.omit(ts_serie_semaine), s.window = "periodic")
autoplot(decomp_ts)
```

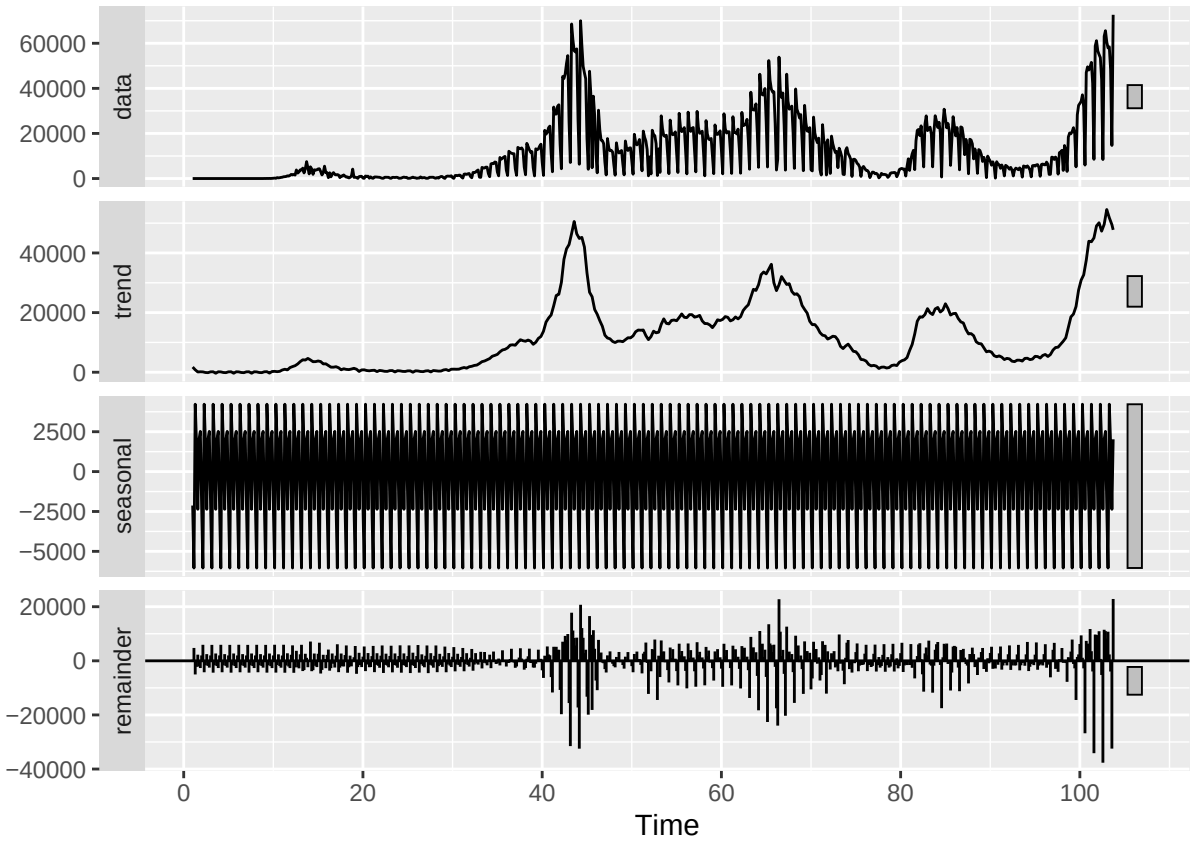

Retrait de la tendance / saisonnalité

Nous cherchons à nous ramener à une série sans tendance. Afin de la retirer de notre série, nous allons utiliser l'opérateur diff. Nous allons donc construire un filtre permettant de construire notre analyse.

Tout d'abord, nous avons décider de ne pas transformer notre série en logarithme. Celle-ci nous permettrait de réduire sa variance mais puisque la série présente des valeurs nulles, cette transformation n'est pas pertinente.

Nous allons donc différencier la série.

```
ndiffs(ts_serie_semaine) # On nous conseille de différencier la série 1 fois
```

```
## [1] 1
```

```
serie_lissee <- ts_serie_semaine |>
  diff(lag=1)

ndiffs(serie_lissee) # la série a été différencié comme il faut
```

```
## [1] 0
```

Puisque l'on différencie une seule fois, la variance augmente mais reste plus faible que si l'on avait différencié 3 ou 4 fois par exemple.

```
serie_lissee |>
  ggtsdisplay(plot.type = "scatter",smooth=FALSE)
```

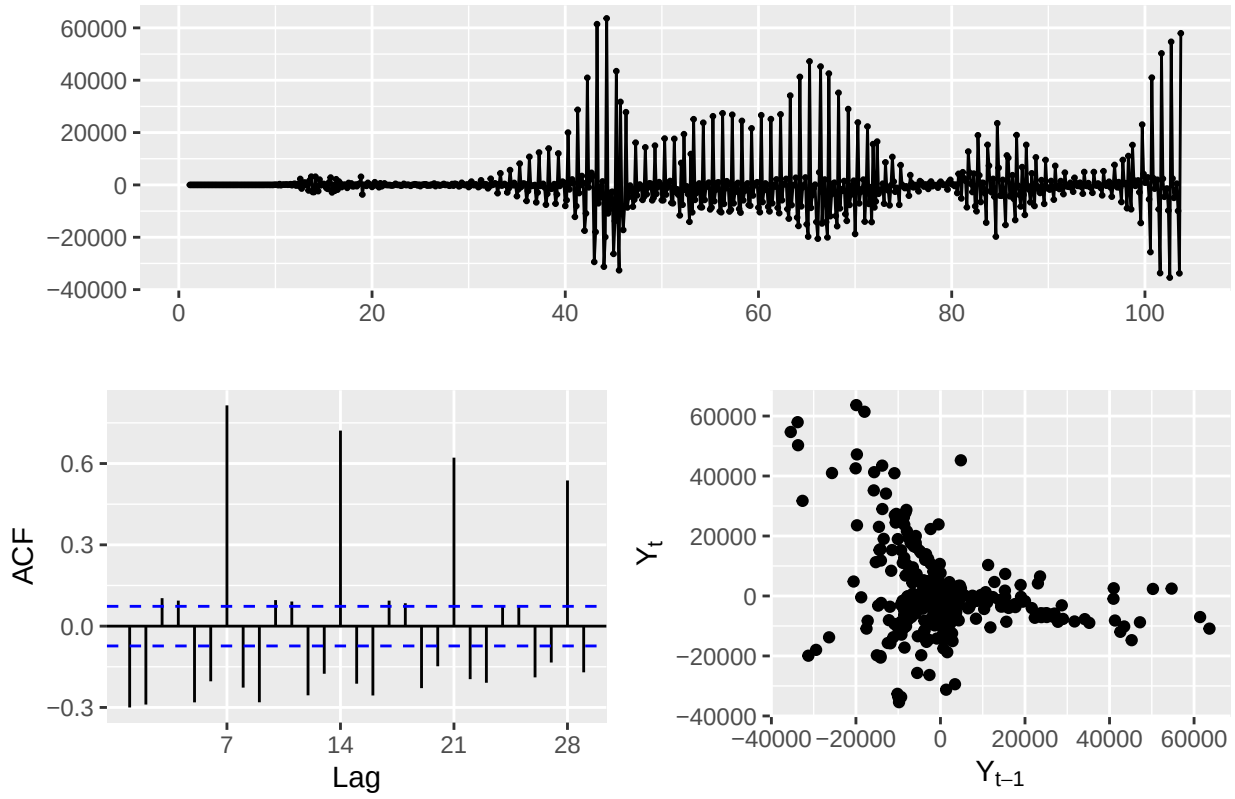

Grâce à cette méthode, nous pouvons faire plusieurs constats : - **Le chronogramme** : Notre différenciation nous permet de stationariser notre série et supprimer la tendance. Nous pouvons donc émettre l'hypothèse d'un modèle polynomial.

- **L'ACF** : L'auto-corrélation décroit car on fait des moyennes sur de moins en moins de valeurs. De plus, nous pouvons observer une saisonnalité hebdomadaire avec un pic tous les 7 jours (lag).
- **Corrélation** : Le nuage de points ne présente pas de direction.

Retrait de la saisonnalité

Pour pouvoir réaliser des tests de stationnarité, nous devons d'abord avoir une série sans tendance ni de saisonnalité.

Ici, notre série n'a plus de tendance, il faut maintenant enlever la saisonnalité.

```
ts.plot(serie_lissee, main = "Serie différenciée", col ="blue")
```

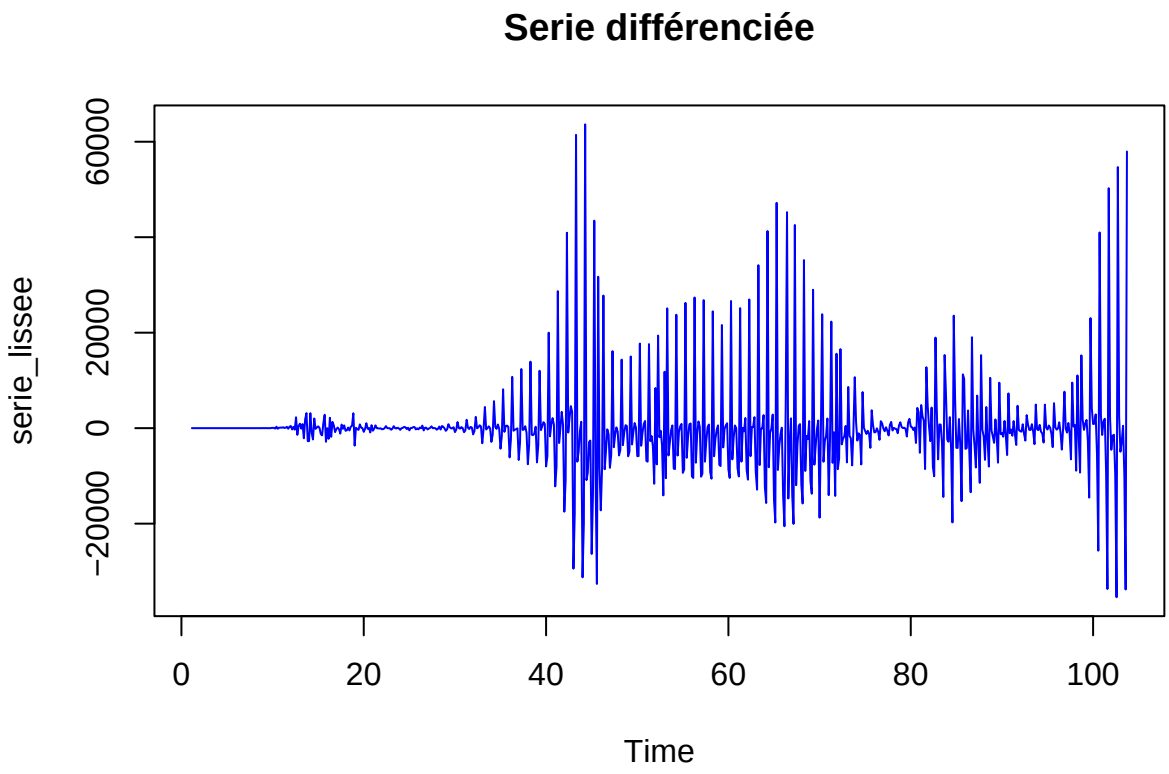

Stationnarité

Ensuite, nous allons tester la stationnarité de notre série :

```
kpss.test(serie_lissee)
```

```
## Warning in kpss.test(serie_lissee): p-value greater than printed p-value
```

```
##
##  KPSS Test for Level Stationarity
##
## data:  serie_lissee
## KPSS Level = 0.26302, Truncation lag parameter = 6, p-value = 0.1
```

Nous avons une p-value associée au test supérieure à 5%, nous rejettons donc l'hypothèse nulle de stationnarité. Notre série n'est donc pas stationnaire.

```
adf.test(serie_lissee)
```

```
## Warning in adf.test(serie_lissee): p-value smaller than printed p-value
```

```
##
##  Augmented Dickey-Fuller Test
```

```
##
## data:  serie_lissee
## Dickey-Fuller = -6.9851, Lag order = 8, p-value = 0.01
## alternative hypothesis: stationary
```

Lors de ce test, nous obtenons une p-value inférieure à 5%. Nous acceptons l'hypothèse de non-stationnarité. Ce test nous permet de confirmer notre hypothèse précédente.

En conclusion, notre série n'est pas **stationnaire**.

Détection de l'autocorrélation partielle et identification des degrés p et q

Afin de détecter la présence d'autocorrélation partielle, nous allons utiliser la fonction pacf. Elle nous permet de mesurer l'aurocorrélation d'un signal pour un décalage k "indépendamment" des autocorrélations pour les décalages inférieurs.
Nous avons choisi d'utiliser cette fonction car le corrélogramme produit par la fonction ggdisplay montre des autocorrélations fortes à répétition.

```
pacf(serie_lissee)
```

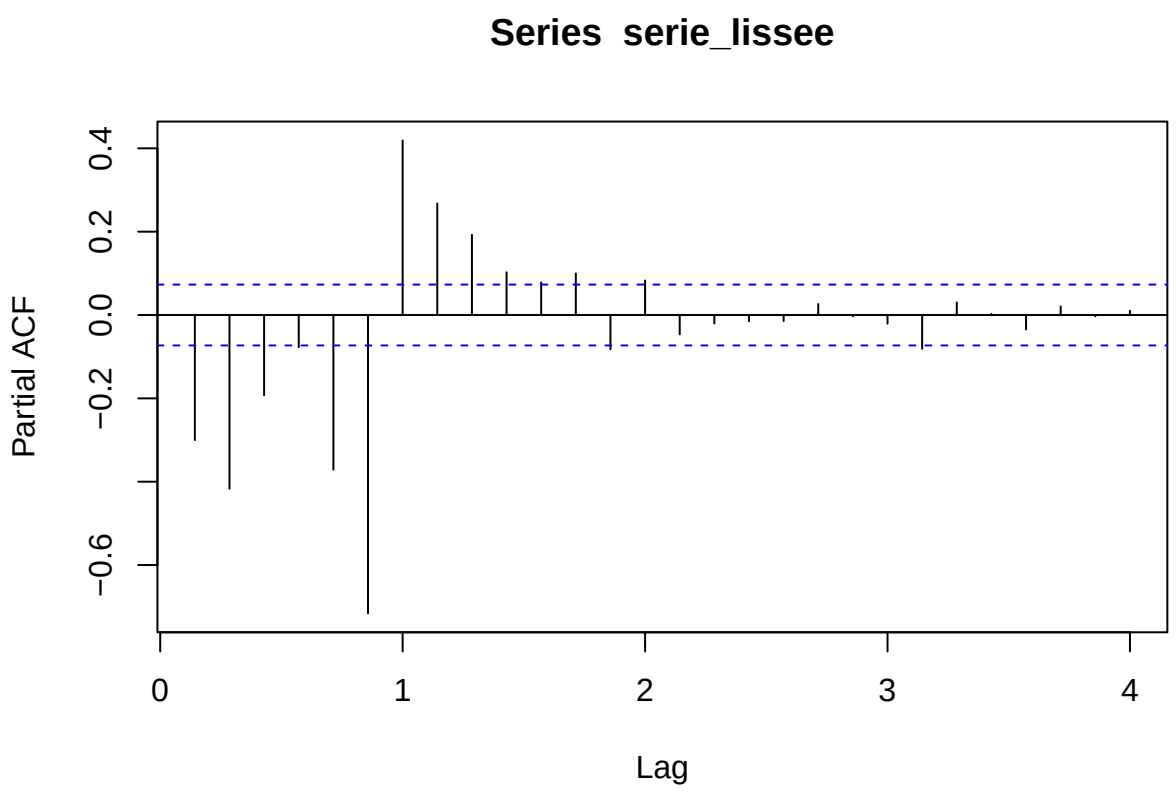


```
acf2y(serie_lissee,lag.max = 15)
```

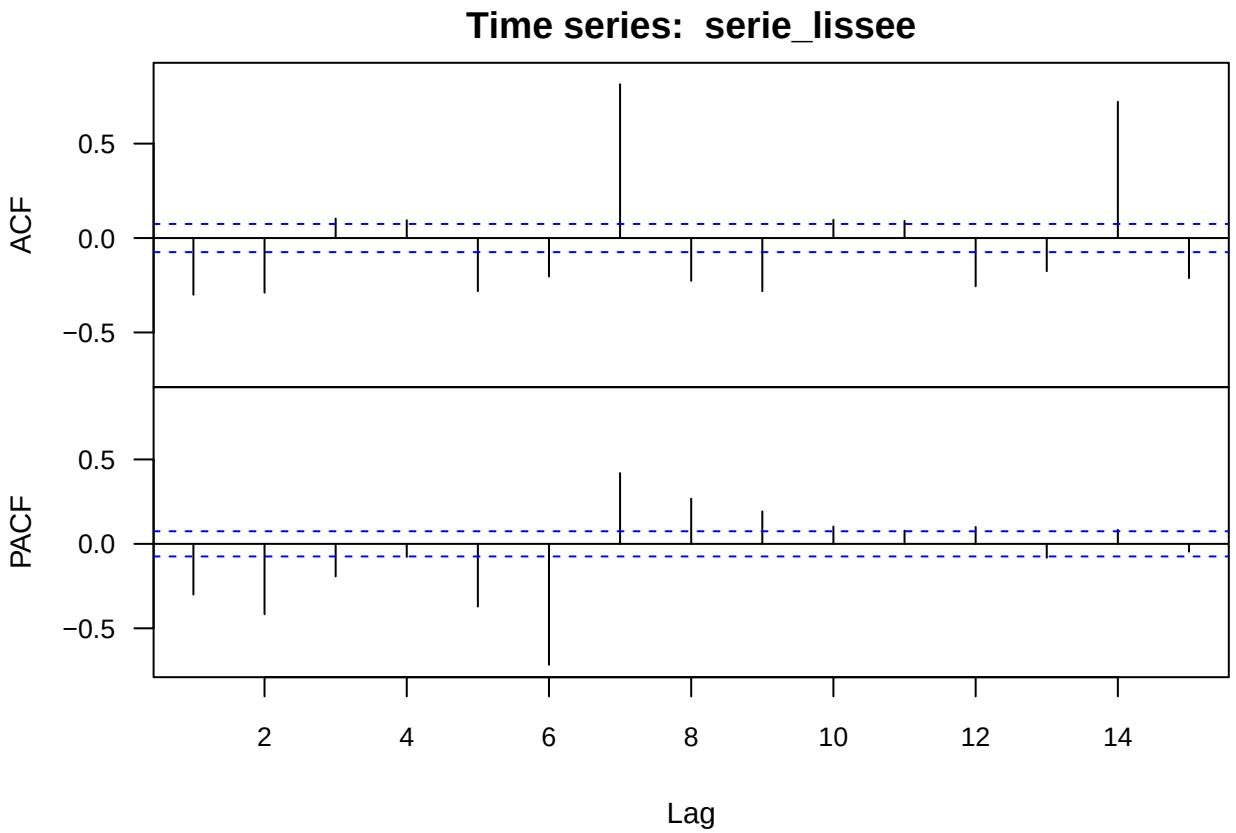


```
##       LAG        ACF1        PACF
##  [1,]   1 -0.30006607 -0.30006607
##  [2,]   2 -0.28932338 -0.41690062
##  [3,]   3  0.10323365 -0.19270179
##  [4,]   4  0.09411426 -0.07714966
##  [5,]   5 -0.28121680 -0.37099581
##  [6,]   6 -0.20356944 -0.71598887
##  [7,]   7  0.81450655  0.41882851
##  [8,]   8 -0.22680907  0.26782417
##  [9,]   9 -0.28089902  0.19242924
## [10,]  10  0.09603546  0.10251255
## [11,]  11  0.09084251  0.07823376
## [12,]  12 -0.25529630  0.09978066
## [13,]  13 -0.17562952 -0.08206719
## [14,]  14  0.72149907  0.08291360
## [15,]  15 -0.21237168 -0.04646638
```

Estimation du modèle

Nous allons essayer de choisir le meilleur modèle afin d'estimer notre série.

Afin de pouvoir estimer le modèle, nous avons utiliser la fonction auto.arima() du package forecast qui permet d'effectuer une modélisation automatique. En précisant les arguments trace=T et ic=aic, nous avons donner la main au logiciel R de selectionner le meilleur modèle sur la base du critère AIC

```r
model_arima <- auto.arima(serie_lissee, trace=T, ic = "aic")
```

ARIMA

```
##
##  Fitting models using approximations to speed things up...
##
##  ARIMA(2,0,2)(1,1,1)[7] with drift         : 13847.67
##  ARIMA(0,0,0)(0,1,0)[7] with drift         : 14195.3
##  ARIMA(1,0,0)(1,1,0)[7] with drift         : 13985.9
##  ARIMA(0,0,1)(0,1,1)[7] with drift         : 13852.64
##  ARIMA(0,0,0)(0,1,0)[7]                    : 14193.3
##  ARIMA(2,0,2)(0,1,1)[7] with drift         : 13847.43
##  ARIMA(2,0,2)(0,1,0)[7] with drift         : 13882.05
##  ARIMA(2,0,2)(0,1,2)[7] with drift         : 13849.42
##  ARIMA(2,0,2)(1,1,0)[7] with drift         : 13855.43
##  ARIMA(2,0,2)(1,1,2)[7] with drift         : Inf
##  ARIMA(1,0,2)(0,1,1)[7] with drift         : 13857.44
##  ARIMA(2,0,1)(0,1,1)[7] with drift         : 13854.16
##  ARIMA(3,0,2)(0,1,1)[7] with drift         : Inf
##  ARIMA(2,0,3)(0,1,1)[7] with drift         : 13847.45
##  ARIMA(1,0,1)(0,1,1)[7] with drift         : 13855.53
##  ARIMA(1,0,3)(0,1,1)[7] with drift         : 13846.98
##  ARIMA(1,0,3)(0,1,0)[7] with drift         : 13881.03
##  ARIMA(1,0,3)(1,1,1)[7] with drift         : 13846.76
##  ARIMA(1,0,3)(1,1,0)[7] with drift         : 13855.17
##  ARIMA(1,0,3)(2,1,1)[7] with drift         : 13846.9
##  ARIMA(1,0,3)(1,1,2)[7] with drift         : 13857.54
##  ARIMA(1,0,3)(0,1,2)[7] with drift         : 13848.97
##  ARIMA(1,0,3)(2,1,0)[7] with drift         : 13863.74
##  ARIMA(1,0,3)(2,1,2)[7] with drift         : 13847.32
##  ARIMA(0,0,3)(1,1,1)[7] with drift         : 13845.78
##  ARIMA(0,0,3)(0,1,1)[7] with drift         : 13850.7
##  ARIMA(0,0,3)(1,1,0)[7] with drift         : 13858.58
##  ARIMA(0,0,3)(2,1,1)[7] with drift         : 13849.71
##  ARIMA(0,0,3)(1,1,2)[7] with drift         : Inf
##  ARIMA(0,0,3)(0,1,0)[7] with drift         : 13878.07
##  ARIMA(0,0,3)(0,1,2)[7] with drift         : 13852.59
##  ARIMA(0,0,3)(2,1,0)[7] with drift         : 13867.4
##  ARIMA(0,0,3)(2,1,2)[7] with drift         : 13849.79
##  ARIMA(0,0,2)(1,1,1)[7] with drift         : 13847.62
##  ARIMA(0,0,4)(1,1,1)[7] with drift         : 13846.85
##  ARIMA(1,0,2)(1,1,1)[7] with drift         : 13850.64
##  ARIMA(1,0,4)(1,1,1)[7] with drift         : Inf
##  ARIMA(0,0,3)(1,1,1)[7]                    : 13843.91
##  ARIMA(0,0,3)(0,1,1)[7]                    : 13848.74
##  ARIMA(0,0,3)(1,1,0)[7]                    : 13856.61
##  ARIMA(0,0,3)(2,1,1)[7]                    : 13847.82
##  ARIMA(0,0,3)(1,1,2)[7]                    : Inf
##  ARIMA(0,0,3)(0,1,0)[7]                    : 13876.1
##  ARIMA(0,0,3)(0,1,2)[7]                    : 13850.63
##  ARIMA(0,0,3)(2,1,0)[7]                    : 13865.43
```

```
##  ARIMA(0,0,3)(2,1,2)[7]                    : 13847.9
##  ARIMA(0,0,2)(1,1,1)[7]                    : 13845.76
##  ARIMA(1,0,3)(1,1,1)[7]                    : 13844.88
##  ARIMA(0,0,4)(1,1,1)[7]                    : 13844.98
##  ARIMA(1,0,2)(1,1,1)[7]                    : 13848.81
##  ARIMA(1,0,4)(1,1,1)[7]                    : Inf
##
##  Now re-fitting the best model(s) without approximations...
##
##  ARIMA(0,0,3)(1,1,1)[7]                    : 13960.51
##
##  Best model: ARIMA(0,0,3)(1,1,1)[7]
```

Modèle identifier : ARIMA(4,0,4)

```
summary(model_arima)
```

```
## Series: serie_lissee
## ARIMA(0,0,3)(1,1,1)[7]
##
## Coefficients:
##          ma1      ma2     ma3    sar1     sma1
##       -0.7378  -0.0419  0.0793  0.7009  -0.8852
## s.e.   0.0380   0.0462  0.0394  0.0554   0.0379
##
## sigma^2 = 18925739:  log likelihood = -6974.25
## AIC=13960.51   AICc=13960.63   BIC=13987.92
##
## Training set error measures:
##                     ME     RMSE     MAE MPE MAPE      MASE        ACF1
## Training set 53.96374 4313.916 2168.68 NaN  Inf 0.9191823 0.001809301
```

```
t_stat(model_arima)
```

```
##              ma1       ma2      ma3     sar1      sma1
## t.stat -19.44142 -0.906692 2.013372 12.65306 -23.37544
## p.val    0.00000  0.364570 0.044075  0.00000   0.00000
```

Le modèle n'est pas simplifiable

```
arima <- auto.arima(serie_lissee,d=1,D=1,stepwise = FALSE,approximation=FALSE,trace=TRUE)
```

```
##
##  ARIMA(0,1,0)(0,1,0)[7]                    : 15066.25
##  ARIMA(0,1,0)(0,1,1)[7]                    : 14975.66
##  ARIMA(0,1,0)(0,1,2)[7]                    : 14977.62
##  ARIMA(0,1,0)(1,1,0)[7]                    : 14983.42
##  ARIMA(0,1,0)(1,1,1)[7]                    : 14977.6
##  ARIMA(0,1,0)(1,1,2)[7]                    : 14979.54
##  ARIMA(0,1,0)(2,1,0)[7]                    : 14978.99
##  ARIMA(0,1,0)(2,1,1)[7]                    : 14967.8
##  ARIMA(0,1,0)(2,1,2)[7]                    : 14969.71
```

```
##  ARIMA(0,1,1)(0,1,0)[7]                    : Inf
##  ARIMA(0,1,1)(0,1,1)[7]                    : Inf
##  ARIMA(0,1,1)(0,1,2)[7]                    : Inf
##  ARIMA(0,1,1)(1,1,0)[7]                    : Inf
##  ARIMA(0,1,1)(1,1,1)[7]                    : Inf
##  ARIMA(0,1,1)(1,1,2)[7]                    : Inf
##  ARIMA(0,1,1)(2,1,0)[7]                    : Inf
##  ARIMA(0,1,1)(2,1,1)[7]                    : Inf
##  ARIMA(0,1,1)(2,1,2)[7]                    : Inf
##  ARIMA(0,1,2)(0,1,0)[7]                    : Inf
##  ARIMA(0,1,2)(0,1,1)[7]                    : Inf
##  ARIMA(0,1,2)(0,1,2)[7]                    : Inf
##  ARIMA(0,1,2)(1,1,0)[7]                    : Inf
##  ARIMA(0,1,2)(1,1,1)[7]                    : Inf
##  ARIMA(0,1,2)(1,1,2)[7]                    : Inf
##  ARIMA(0,1,2)(2,1,0)[7]                    : Inf
##  ARIMA(0,1,2)(2,1,1)[7]                    : Inf
##  ARIMA(0,1,3)(0,1,0)[7]                    : Inf
##  ARIMA(0,1,3)(0,1,1)[7]                    : Inf
##  ARIMA(0,1,3)(0,1,2)[7]                    : Inf
##  ARIMA(0,1,3)(1,1,0)[7]                    : Inf
##  ARIMA(0,1,3)(1,1,1)[7]                    : Inf
##  ARIMA(0,1,3)(2,1,0)[7]                    : Inf
##  ARIMA(0,1,4)(0,1,0)[7]                    : Inf
##  ARIMA(0,1,4)(0,1,1)[7]                    : Inf
##  ARIMA(0,1,4)(1,1,0)[7]                    : Inf
##  ARIMA(0,1,5)(0,1,0)[7]                    : Inf
##  ARIMA(1,1,0)(0,1,0)[7]                    : 14674.62
##  ARIMA(1,1,0)(0,1,1)[7]                    : 14629.5
##  ARIMA(1,1,0)(0,1,2)[7]                    : 14629.97
##  ARIMA(1,1,0)(1,1,0)[7]                    : 14627.49
##  ARIMA(1,1,0)(1,1,1)[7]                    : 14629.47
##  ARIMA(1,1,0)(1,1,2)[7]                    : 14631.5
##  ARIMA(1,1,0)(2,1,0)[7]                    : 14629.47
##  ARIMA(1,1,0)(2,1,1)[7]                    : Inf
##  ARIMA(1,1,0)(2,1,2)[7]                    : Inf
##  ARIMA(1,1,1)(0,1,0)[7]                    : Inf
##  ARIMA(1,1,1)(0,1,1)[7]                    : Inf
##  ARIMA(1,1,1)(0,1,2)[7]                    : Inf
##  ARIMA(1,1,1)(1,1,0)[7]                    : Inf
##  ARIMA(1,1,1)(1,1,1)[7]                    : Inf
##  ARIMA(1,1,1)(1,1,2)[7]                    : Inf
##  ARIMA(1,1,1)(2,1,0)[7]                    : Inf
##  ARIMA(1,1,1)(2,1,1)[7]                    : Inf
##  ARIMA(1,1,2)(0,1,0)[7]                    : Inf
##  ARIMA(1,1,2)(0,1,1)[7]                    : Inf
##  ARIMA(1,1,2)(0,1,2)[7]                    : Inf
##  ARIMA(1,1,2)(1,1,0)[7]                    : Inf
##  ARIMA(1,1,2)(1,1,1)[7]                    : Inf
##  ARIMA(1,1,2)(2,1,0)[7]                    : Inf
##  ARIMA(1,1,3)(0,1,0)[7]                    : Inf
##  ARIMA(1,1,3)(0,1,1)[7]                    : Inf
##  ARIMA(1,1,3)(1,1,0)[7]                    : Inf
##  ARIMA(1,1,4)(0,1,0)[7]                    : Inf
```

```
##  ARIMA(2,1,0)(0,1,0)[7]                    : 14454.29
##  ARIMA(2,1,0)(0,1,1)[7]                    : 14419.05
##  ARIMA(2,1,0)(0,1,2)[7]                    : 14420.49
##  ARIMA(2,1,0)(1,1,0)[7]                    : 14418.3
##  ARIMA(2,1,0)(1,1,1)[7]                    : 14420.23
##  ARIMA(2,1,0)(1,1,2)[7]                    : 14422.18
##  ARIMA(2,1,0)(2,1,0)[7]                    : 14420.24
##  ARIMA(2,1,0)(2,1,1)[7]                    : Inf
##  ARIMA(2,1,1)(0,1,0)[7]                    : Inf
##  ARIMA(2,1,1)(0,1,1)[7]                    : Inf
##  ARIMA(2,1,1)(0,1,2)[7]                    : Inf
##  ARIMA(2,1,1)(1,1,0)[7]                    : Inf
##  ARIMA(2,1,1)(1,1,1)[7]                    : Inf
##  ARIMA(2,1,1)(2,1,0)[7]                    : Inf
##  ARIMA(2,1,2)(0,1,0)[7]                    : Inf
##  ARIMA(2,1,2)(0,1,1)[7]                    : Inf
##  ARIMA(2,1,2)(1,1,0)[7]                    : Inf
##  ARIMA(2,1,3)(0,1,0)[7]                    : Inf
##  ARIMA(3,1,0)(0,1,0)[7]                    : 14335.88
##  ARIMA(3,1,0)(0,1,1)[7]                    : 14300.78
##  ARIMA(3,1,0)(0,1,2)[7]                    : 14302.74
##  ARIMA(3,1,0)(1,1,0)[7]                    : 14301.17
##  ARIMA(3,1,0)(1,1,1)[7]                    : 14302.67
##  ARIMA(3,1,0)(2,1,0)[7]                    : 14302.83
##  ARIMA(3,1,1)(0,1,0)[7]                    : Inf
##  ARIMA(3,1,1)(0,1,1)[7]                    : Inf
##  ARIMA(3,1,1)(1,1,0)[7]                    : Inf
##  ARIMA(3,1,2)(0,1,0)[7]                    : Inf
##  ARIMA(4,1,0)(0,1,0)[7]                    : 14279.74
##  ARIMA(4,1,0)(0,1,1)[7]                    : 14251.3
##  ARIMA(4,1,0)(1,1,0)[7]                    : 14249.87
##  ARIMA(4,1,1)(0,1,0)[7]                    : Inf
##  ARIMA(5,1,0)(0,1,0)[7]                    : 14120.14
##
##
##
##  Best model: ARIMA(5,1,0)(0,1,0)[7]
```

```
summary(arima)
```

```
## Series: serie_lissee
## ARIMA(5,1,0)(0,1,0)[7]
##
## Coefficients:
##           ar1      ar2      ar3      ar4      ar5
##       -1.4326  -1.4942  -1.2548  -0.8679  -0.4494
## s.e.   0.0335   0.0542   0.0621   0.0541   0.0333
##
## sigma^2 = 24330838:  log likelihood = -7054.01
## AIC=14120.02   AICc=14120.14   BIC=14147.42
##
## Training set error measures:
##                     ME     RMSE      MAE MPE MAPE     MASE        ACF1
## Training set 9.117739 4887.834 2432.324 NaN  Inf 1.030926 -0.04273681
```

```
t_stat(arima)
```

```
##              ar1       ar2       ar3       ar4       ar5
## t.stat -42.82825 -27.55514 -20.21309 -16.04953 -13.49368
## p.val    0.00000   0.00000   0.00000   0.00000   0.00000
```

```
Box.test.2(arima$residuals,nlag=c(6,12,18,24,30,36),type="Ljung-Box",decim=5)
```

```
##      Retard p-value
## [1,]      6       0
## [2,]     12       0
## [3,]     18       0
## [4,]     24       0
## [5,]     30       0
## [6,]     36       0
```

Estimation par régression linéaire (MCO)

```
t <- 1:length(ts_serie1)
x <- outer(t,1:6)*(pi/6)
df <- data.frame(ts_serie1,t,cos(x),sin(x[,-6]))
ts_serie1_lm <- lm(data=df,ts_serie1~.)

summary(ts_serie1_lm)
```

```
##
## Call:
## lm(formula = ts_serie1 ~ ., data = df)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -19426  -7072  -2665   4848  60392
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1456.745    971.698   1.499    0.134
## t             28.590      2.335  12.243   <2e-16 ***
## X1          -157.233    686.311  -0.229    0.819
## X2           355.712    686.311   0.518    0.604
## X3             6.227    686.311   0.009    0.993
## X4           274.870    686.311   0.401    0.689
## X5           241.654    686.311   0.352    0.725
## X6            61.208    485.294   0.126    0.900
## X1.1        -228.513    686.363  -0.333    0.739
## X2.1        -177.238    686.319  -0.258    0.796
## X3.1         -80.877    686.311  -0.118    0.906
## X4.1         -61.130    686.309  -0.089    0.929
## X5.1         188.947    686.308   0.275    0.783
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 13020 on 707 degrees of freedom
## Multiple R-squared:  0.1761, Adjusted R-squared:  0.1621
## F-statistic: 12.59 on 12 and 707 DF,  p-value: < 2.2e-16
```

Etude des résidus

–> test de blancheur : box.test

La fonction Box.test(serie,lag=H) examine l'hypothèse nulle de nullité des H première auto-covariance, à l'aide du test du portemanteau. Par défaut H est fixé à 1, et seule la nullité de l'auto-covariance d'ordre 1 est testée. Pour tester si la série peut-être apparentée à un bruit blanc, nous fixerons arbitrairement un H de l'ordre de 20 (nous considérerons abusivement que si les 20 premières auto-corrélations sont nulles, la série est indépendante). La première valeur affichée est la statistique du test. La p-value est la probabilité d'obtenir une valeur aussi élevée sous l'hypothèse nulle. Si nous voulons faire un test au niveau de confiance 0.95 : dans le cas où cette valeur est < 0.05, nous rejetons l'hypothèse nulle.

```
Box.test(ts_serie1,lag=12)
```

```
##
##  Box-Pierce test
##
## data:  ts_serie1
## X-squared = 3688.8, df = 12, p-value < 2.2e-16
```

L'hypothèse de non-autocorrélation de la série temporelle peut être rejetée avec une confiance de 95%. Cela implique que la série temporelle présente une autocorrélation significative et que les valeurs successives de la série temporelle sont dépendantes les unes des autres.

–> test de durbin watson : test auto corrélation des erreurs du modele arima

```
# dwtest(arima)
```